

Clustering Δεδομένων Γράφου με Μεθόδους Μηχανικής Μάθησης



Ονοματεπώνυμο: Παντελεήμων Τζεχερίδης

ΑΕΜ: 3650

Είδος έργου: Πτυχιακή Εργασία

Επιβλέπων Καθηγητής: Απόστολος Τσιάκαλος

Ημερομηνία υποβολής: Ιούλιος 2025

Αριστοτέλειο Πανεπιστήμιο Θεσσαλονίκης – Τμήμα Πληροφορικής



Πίνακας Περιεχομένων

1-Εισαγωγή

- 1.1 Το αντικείμενο της εργασίας
 - 1.2 Στόχοι και συνεισφορά
 - 1.3 Δομή της εργασίας
-

2-Θεωρητικό Υπόβαθρο

- 2.1 Θεωρία Γράφων
 - 2.1.1 Βασικοί ορισμοί και έννοιες
 - 2.1.2 Χαρακτηριστικά γράφων (βαθμός, πυκνότητα κλπ.)
 - 2.2 Τεχνικές Ενσωμάτωσης Κόμβων (Graph Embedding)
 - 2.2.1 Node2Vec
 - 2.2.2 Graph Convolutional Networks (GCN)
 - 2.2.3 GraphSAGE
 - 2.3 Μέθοδοι Ομαδοποίησης (Clustering)
 - 2.3.1 K-means
 - 2.3.2 DBSCAN
 - 2.3.3 Spectral Clustering
 - 2.4 Μετρικές αξιολόγησης αποτελεσμάτων clustering
 - 2.4.1 Adjusted Rand Index (ARI)
 - 2.4.2 Normalized Mutual Information (NMI)
 - 2.4.3 Silhouette Score
-

3-Μεθοδολογία

- 3.1 Επιλογή και περιγραφή datasets
 - 3.2 Εξαγωγή embeddings
 - 3.3 Εφαρμογή clustering
 - 3.4 Αξιολόγηση και εργαλεία
-

4-Οπτικοποίηση και Ανάλυση Embeddings

- 4.1 Σκοπός και προσέγγιση
 - 4.2 Embeddings για το dataset Citeseet
 - 4.3 Embeddings για το dataset Cora
 - 4.4 Συγκριτική παρατήρηση και συνολική εικόνα
-

5-Αποτελέσματα Clustering και Σύγκριση

- 5.1 Παρουσίαση αποτελεσμάτων ανά clustering μέθοδο (KMeans, DBSCAN, Spectral, GMM)
 - 5.2 Παρουσίαση πινάκων με τις μετρικές (ARI, NMI, Silhouette)
 - 5.3 Συγκριτική ανάλυση μεταξύ μοντέλων (GCN vs GraphSAGE vs Node2Vec)
 - 5.4 Συζήτηση για τα datasets (Cora vs Citeseer)
-

6-Συμπεράσματα και Μελλοντικές Κατευθύνσεις

- 6.1 Ανακεφαλαίωση
 - 6.2 Μελλοντική επέκταση και βελτίωση
-

Παραρτήματα

- Κώδικας



Βιβλιογραφία

- [1] Grover, A., & Leskovec, J. (2016). *node2vec: Scalable Feature Learning for Networks*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
- [2] Kipf, T. N., & Welling, M. (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. International Conference on Learning Representations (ICLR 2017).
- [3] Hamilton, W., Ying, Z., & Leskovec, J. (2017). *Inductive Representation Learning on Large Graphs*. Advances in Neural Information Processing Systems (NeurIPS 2017).
- [4] Luxburg, U. V. (2007). *A Tutorial on Spectral Clustering*. Statistics and Computing.
- [5] Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*. In Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD'96).
- [6] Θεωρία και Αλγόριθμοι γράφων(2014). Ιωάννης Μανωλόπουλος, Απόστολος Παπαδόπουλος,Κωνσταντίνος Τσίχλας,Εκδόσεις νέων Τεχνολογιών

Κεφάλαιο 1 – Εισαγωγή

1.1 Το αντικείμενο της εργασίας

Τα τελευταία χρόνια, η ανάλυση γράφων έχει κερδίσει ιδιαίτερο ενδιαφέρον, καθώς πολλαπλά πραγματικά δεδομένα μπορούν να αναπαρασταθούν με τη μορφή γράφων: κοινωνικά δίκτυα, δίκτυα επιστημονικών αναφορών, βιολογικά δίκτυα και πολλά άλλα.

Η ανάγκη για κατανόηση και εξαγωγή γνώσης από αυτά τα δεδομένα οδήγησε στην ανάπτυξη τεχνικών που μετασχηματίζουν τους κόμβους ενός γράφου σε χαμηλότερης διάστασης διανυσματικές αναπαραστάσεις (embeddings). Με αυτόν τον τρόπο, μπορούμε να εφαρμόσουμε κλασικές μεθόδους μηχανικής μάθησης, όπως ομαδοποίηση (clustering), πάνω στους κόμβους.

Η παρούσα εργασία έχει ως στόχο την εξαγωγή και αξιολόγηση τέτοιων embeddings με διάφορες σύγχρονες τεχνικές και την εφαρμογή αλγορίθμων ομαδοποίησης, ώστε να αναδείξει ποια μέθοδος οδηγεί σε καλύτερη διαχωριστικότητα και ποιότητα ομάδων.

1.2 Στόχοι και συνεισφορά

Συνοπτικά, οι κύριοι στόχοι της πτυχιακής εργασίας είναι:

- Η μελέτη και εφαρμογή διαφορετικών τεχνικών εξαγωγής embeddings για κόμβους γράφων, όπως οι Node2Vec και Graph Convolutional Networks (GCN).
- Η εφαρμογή μεθόδων clustering στα παραγόμενα embeddings (K-means, DBSCAN, Spectral Clustering).
- Η ποσοτική και οπτική αξιολόγηση των αποτελεσμάτων με δείκτες όπως ARI, NMI και Silhouette Score.
- Η σύγκριση των τεχνικών μεταξύ τους, ώστε να εντοπιστούν τα πλεονεκτήματα και μειονεκτήματα κάθε προσέγγισης.

Η συνεισφορά της εργασίας εστιάζει:

- Στην ολοκληρωμένη σύγκριση διαφορετικών τεχνικών embeddings σε κοινά datasets.
- Στην παροχή ενός αναλυτικού πειραματικού πλαισίου που μπορεί να αξιοποιηθεί και για μελλοντικές εργασίες.

1.3 Δομή της εργασίας

Η δομή της εργασίας οργανώνεται ως εξής:

- Στο **Κεφάλαιο 2** παρουσιάζεται το θεωρητικό υπόβαθρο που αφορά τη θεωρία γράφων, τις τεχνικές embeddings, τις μεθόδους clustering και τις μετρικές αξιολόγησης.

- Στο **Κεφάλαιο 3** περιγράφεται η μεθοδολογία που ακολουθήθηκε: επιλογή datasets, εξαγωγή embeddings, εφαρμογή clustering και αξιολόγηση.
- Στο **Κεφάλαιο 4** παρουσιάζονται τα πειραματικά αποτελέσματα, οι συγκρίσεις και οι οπτικοποιήσεις.
- Στο **Κεφάλαιο 5** γίνεται ανάλυση και συζήτηση των αποτελεσμάτων.
- Τέλος, στο **Κεφάλαιο 6** συνοψίζονται τα συμπεράσματα και προτείνονται ιδέες για μελλοντική επέκταση της εργασίας.

Κεφάλαιο 2 – Θεωρητικό Υπόβαθρο

2.1 Θεωρία Γράφων

2.1.1 Βασικοί ορισμοί και έννοιες

Ένας γράφος $G=(V,E)$ αποτελείται από ένα σύνολο κόμβων (ή κορυφών) V και ένα σύνολο ακμών E που συνδέουν τα ζεύγη κόμβων. Οι ακμές μπορεί να είναι κατευθυνόμενες ή μη κατευθυνόμενες, αναλόγως του αν η κατεύθυνση της σχέσης έχει σημασία.

Η θεωρία γράφων χρησιμοποιείται ευρέως για την αναπαράσταση πολύπλοκων δομών και σχέσεων μεταξύ αντικειμένων.

2.1.2 Χαρακτηριστικά γράφων

Ορισμένα βασικά χαρακτηριστικά που μελετώνται στους γράφους είναι:

- **Βαθμός κόμβου (degree):** αριθμός ακμών που συνδέονται με έναν κόμβο.
- **Πυκνότητα (density):** μέτρο του πόσο "γεμάτος" είναι ο γράφος σε σχέση με τον μέγιστο αριθμό ακμών.
- **Συνδετικότητα:** πόσο καλά συνδέονται οι κόμβοι μεταξύ τους.
- **Κεντρικότητα (centrality):** μετρικές που δείχνουν τη σχετική σημασία κάθε κόμβου.

Οι ιδιότητες αυτές παίζουν σημαντικό ρόλο στην κατανόηση της δομής του γράφου και στη συμπεριφορά αλγορίθμων που εφαρμόζονται πάνω του.

2.2 Τεχνικές Ενσωμάτωσης Κόμβων (Graph Embedding)

Οι τεχνικές embeddings επιδιώκουν να μετατρέψουν κάθε κόμβο σε ένα διάνυσμα χαμηλής διάστασης, διατηρώντας ταυτόχρονα τη μορφή και τις σχέσεις του αρχικού γράφου. Με αυτό τον τρόπο, επιτρέπουν την εφαρμογή κλασικών τεχνικών μηχανικής μάθησης (όπως clustering, classification).

2.2.1 Node2Vec

Το Node2Vec είναι μία μέθοδος που στηρίζεται σε στοχαστικά μονοπάτια (random walks) πάνω στον γράφο και αξιοποιεί το μοντέλο Skip-gram, εμπνευσμένο από την επεξεργασία φυσικής γλώσσας (NLP).

Με συνδυασμό παραμέτρων, όπως το p και q , ρυθμίζει πόσο "τοπικά" ή "παγκόσμια" θα είναι τα μονοπάτια, ώστε να αποτυπώνει διαφορετικά χαρακτηριστικά της δομής.

2.2.2 Graph Convolutional Networks (GCN)

Τα GCN αποτελούν μια κατηγορία νευρωνικών δικτύων που γενικεύουν τη λογική της συνέλιξης (convolution) σε δομές γράφων.

Η βασική ιδέα είναι ότι η αναπαράσταση κάθε κόμβου ενημερώνεται συνδυάζοντας πληροφορία από τους γείτονές του. Αυτό επιτρέπει τη δημιουργία embeddings που είναι ευαίσθητα τόσο στη δομή όσο και στα χαρακτηριστικά των κόμβων.

2.2.3 GraphSAGE

Το GraphSAGE (Graph Sample and Aggregate) είναι μια επεκτάσιμη μέθοδος δημιουργίας embeddings για κόμβους σε μεγάλους γράφους.

Η βασική του ιδέα είναι να γενικεύσει σε κόμβους που δεν έχουν εμφανιστεί στο training set, κάνοντας χρήση τοπικών πληροφοριών από τους γείτονες του κάθε κόμβου.

Αναλυτικότερα, για τον υπολογισμό του embedding ενός κόμβου, το GraphSAGE δεν λαμβάνει υπόψη ολόκληρο τον γράφο, αλλά δειγματοληπτεί ένα υποσύνολο από τους γείτονες και εφαρμόζει μια συνάρτηση σύνοψης (aggregator), όπως μέσος όρος (mean), LSTM ή max pooling, ώστε να ενσωματώσει την πληροφορία τους.

Αυτό επιτρέπει:

- Την επεξεργασία πολύ μεγάλων γράφων (που δεν χωράνε στη μνήμη).
- Τη δημιουργία embeddings και για κόμβους που δεν υπήρχαν κατά την εκπαίδευση, κάνοντας το GraphSAGE κατάλληλο για δυναμικά δίκτυα.

Με αυτό τον τρόπο, το GraphSAGE συνδυάζει την ιδέα του sampling με νευρωνικά δίκτυα, δημιουργώντας αναπαραστάσεις που είναι ευαίσθητες τόσο στη δομή όσο και στα χαρακτηριστικά των κόμβων.

2.3 Μέθοδοι Ομαδοποίησης (Clustering)

Η ομαδοποίηση (clustering) είναι η διαδικασία κατά την οποία τα δεδομένα κατηγοριοποιούνται σε ομάδες (clusters) έτσι ώστε τα αντικείμενα της ίδιας ομάδας να μοιάζουν περισσότερο μεταξύ τους παρά με αντικείμενα άλλων ομάδων. Στην παρούσα εργασία, το clustering εφαρμόζεται στα embeddings των κόμβων που παράγονται από τις τεχνικές node2vec, GCN και GraphSAGE.

2.3.1 K-means

Η πιο ευρέως διαδεδομένη μέθοδος clustering. Σκοπός της είναι να χωρίσει τα δεδομένα σε προκαθορισμένο αριθμό clusters k , ώστε να ελαχιστοποιείται η ενδοομαδική διακύμανση, δηλαδή το άθροισμα των αποστάσεων των σημείων από το κέντρο του αντίστοιχου cluster.

2.3.2 DBSCAN

Μέθοδος βασισμένη στην πυκνότητα των δεδομένων. Δημιουργεί clusters σε περιοχές υψηλής πυκνότητας και αφήνει ως outliers τα σημεία που βρίσκονται σε αραιές περιοχές. Έχει το πλεονέκτημα ότι δεν χρειάζεται να καθοριστεί εκ των προτέρων ο αριθμός των clusters.

2.3.3 Spectral Clustering

Εκμεταλλεύεται τις ιδιοτιμές και τα ιδιοδιανύσματα του πίνακα γειτνίασης ή του κανονικοποιημένου Laplacian του γράφου. Χάρη σε αυτή την αναπαράσταση, μπορεί να ανιχνεύσει μη γραμμικά διαχωρίσιμα clusters που άλλες μέθοδοι δυσκολεύονται να εντοπίσουν.

2.3.4 Gaussian Mixture Model (GMM)

Η μέθοδος Gaussian Mixture Model υποθέτει ότι τα δεδομένα προέρχονται από μείγμα κανονικών κατανομών. Κάθε cluster αντιστοιχεί σε μία κανονική κατανομή, η οποία ορίζεται από τη μέση τιμή (mean) και τη διασπορά (covariance).

Η εκπαίδευση γίνεται συνήθως με τον αλγόριθμο EM (Expectation-Maximization), ο οποίος εκτιμά τις παραμέτρους των κανονικών κατανομών και την πιθανότητα το κάθε σημείο να ανήκει σε κάθε cluster.

Το GMM έχει το πλεονέκτημα ότι μπορεί να δημιουργήσει clusters με ελλειπτικό σχήμα και όχι μόνο σφαιρικά, όπως συμβαίνει με το k-means.

2.4 Μετρικές αξιολόγησης αποτελεσμάτων

Η αξιολόγηση της ποιότητας των αποτελεσμάτων clustering είναι καθοριστική, ειδικά όταν επιθυμούμε να συγκρίνουμε διαφορετικούς αλγορίθμους ή να βελτιώσουμε τα μοντέλα μας.

Ανάλογα με το αν υπάρχουν πραγματικές ετικέτες (labels) ή όχι, διακρίνουμε σε επιβλεπόμενες και μη επιβλεπόμενες μετρικές. Στην παρούσα εργασία χρησιμοποιούνται τόσο μετρικές που συγκρίνουν με ground truth, όσο και μετρικές ανεξάρτητες από labels.

2.4.1 Adjusted Rand Index (ARI)

Η μετρική Adjusted Rand Index διορθώνει το Rand Index ώστε να αφαιρεί την τυχαία συμφωνία που μπορεί να προκύψει απλώς λόγω του πλήθους των clusters και του μεγέθους του dataset.

Το ARI παίρνει τιμές στο διάστημα $[-1, 1]$:

- Τιμή κοντά στο 1 σημαίνει πολύ καλή συμφωνία.
- Τιμή κοντά στο 0 σημαίνει ότι η συμφωνία δεν είναι καλύτερη από το τυχαίο.
- Αρνητική τιμή δείχνει χειρότερη από τυχαία συμφωνία.

Η μετρική αυτή είναι ιδιαίτερα χρήσιμη όταν υπάρχουν ground truth labels και θέλουμε να μετρήσουμε πόσο καλά αναπαράγονται οι πραγματικές δομές από τον αλγόριθμο clustering.

2.4.2 Normalized Mutual Information (NMI)

Η αμοιβαία πληροφορία (Mutual Information) υπολογίζει πόση πληροφορία μοιράζονται δύο κατανομές: η πραγματική κατανομή των labels και η κατανομή που προκύπτει από τον αλγόριθμο clustering.

Η Normalized Mutual Information κανονικοποιεί αυτό το μέγεθος ώστε να παίρνει τιμές στο διάστημα:

- Τιμή κοντά στο 1 σημαίνει ότι τα clusters συμπίπτουν σχεδόν πλήρως με τα πραγματικά labels.
- Τιμή κοντά στο 0 σημαίνει ότι οι δύο κατανομές είναι ουσιαστικά ανεξάρτητες.

Η κανονικοποίηση είναι σημαντική, γιατί κάνει τις τιμές συγκρίσιμες ακόμη και ανάμεσα σε datasets διαφορετικού μεγέθους ή πλήθους clusters.

2.4.3 Silhouette Score

Η μετρική αυτή δεν απαιτεί την ύπαρξη labels (μη επιβλεπόμενη αξιολόγηση) και βασίζεται αποκλειστικά στις αποστάσεις των σημείων μεταξύ τους.

Για κάθε σημείο i :

- Υπολογίζεται η μέση απόσταση $a(i)$ από όλα τα άλλα σημεία του ίδιου cluster.
- Υπολογίζεται η μέση απόσταση $b(i)$ από τα σημεία του πλησιέστερου διαφορετικού cluster.

Το silhouette score για το σημείο i είναι:

$$s(i) = (b(i) - a(i)) / \max\{a(i), b(i)\}$$

Το συνολικό Silhouette Score είναι ο μέσος όρος όλων των $s(i)$ και παίρνει τιμές στο διάστημα $[-1, 1]$:

- Τιμή κοντά στο 1 δείχνει ότι το σημείο έχει τοποθετηθεί σωστά μέσα στο cluster του.
- Τιμή κοντά στο 0 σημαίνει ότι βρίσκεται στα όρια μεταξύ clusters.
- Αρνητική τιμή υποδηλώνει πιθανή λάθος ανάθεση.

Το Silhouette Score είναι ιδιαίτερα χρήσιμο για την επιλογή αριθμού clusters και για τη σύγκριση αλγορίθμων clustering σε περιπτώσεις όπου δεν υπάρχουν ground truth labels.

Κεφάλαιο 3 – Μεθοδολογία

3.1 Επιλογή και περιγραφή datasets


Για τις ανάγκες της παρούσας εργασίας χρησιμοποιήθηκαν δύο ευρέως γνωστά και μελετημένα datasets από τον χώρο της ανάλυσης γράφων και των citation networks: Cora και Citeseer.

Και τα δύο datasets αποτελούνται από κόμβους που αντιπροσωπεύουν επιστημονικές δημοσιεύσεις, ενώ οι ακμές (edges) συνδέουν δημοσιεύσεις που αναφέρονται μεταξύ τους (citation relationships). Επιπλέον, κάθε κόμβος συνοδεύεται από ένα σύνολο χαρακτηριστικών (feature vector) που αποτυπώνουν λέξεις-κλειδιά ή ιδιότητες των αντίστοιχων δημοσιεύσεων.

Cora

- **Αριθμός κόμβων:** ~2.700
- **Αριθμός ακμών:** ~5.400
- **Αριθμός κατηγοριών (classes):** 7
- **Περιγραφή:** Το dataset περιλαμβάνει επιστημονικές δημοσιεύσεις ταξινομημένες σε θεματικές περιοχές (όπως machine learning, information retrieval κ.α.).

Cora Graph Visualization



Citeseer

- **Αριθμός κόμβων:** ~3.300
- **Αριθμός ακμών:** ~4.700
- **Αριθμός κατηγοριών (classes):** 6
- **Περιγραφή:** Αντίστοιχο με το Cora, αλλά με ελαφρώς διαφορετική δομή και θεματική ταξινόμηση. Χαρακτηρίζεται από μεγαλύτερη αραιότητα (sparsity) σε σχέση με το Cora, καθιστώντας την ανάλυση πιο απαιτητική.

Citeseer Graph Visualization



3.2 Εξαγωγή embeddings

Για την εξαγωγή embeddings από τους κόμβους των γράφων Cora και Citeseer, υλοποιήθηκαν τρεις διαφορετικές προσεγγίσεις: GCN (Graph Convolutional Network), GraphSAGE, και node2vec. Στόχος ήταν να συγκριθούν οι αναπαραστάσεις που παράγει κάθε μέθοδος και να διαπιστωθεί ποια οδηγεί σε καλύτερα αποτελέσματα clustering.

3.2.1 GCN (Graph Convolutional Network)

Το πρώτο μοντέλο που χρησιμοποιήθηκε ήταν ένα GCN τριών επιπέδων (layers). Η αρχιτεκτονική του περιλαμβάνει:

- **Πρώτο επίπεδο:** GCNConv από το πλήθος των αρχικών χαρακτηριστικών των κόμβων σε 128 κρυφές διαστάσεις.
- **Δεύτερο επίπεδο:** GCNConv από 128 σε 64 διαστάσεις.
- **Τρίτο επίπεδο:** GCNConv από 64 διαστάσεις στην έξοδο, ίση με τον αριθμό των κατηγοριών του dataset.

Μετά από κάθε κρυφό επίπεδο εφαρμόστηκε η μη γραμμική συνάρτηση ενεργοποίησης ReLU. Η εκπαίδευση έγινε για 500 εποχές, με optimizer Adam, ρυθμό εκμάθησης 0.001 και weight decay $5e-4$. Ως συνάρτηση κόστους χρησιμοποιήθηκε η **cross-entropy**, υπολογιζόμενη στους κόμβους του training set.

Τα τελικά embeddings εξήχθησαν από την έξοδο του μοντέλου μετά την ολοκλήρωση της εκπαίδευσης.

3.2.2 GraphSAGE

Το δεύτερο μοντέλο βασίστηκε στον αλγόριθμο GraphSAGE και περιλαμβάνει επίσης τρία επίπεδα:

- Πρώτο επίπεδο: SAGEConv με 128 κρυφές διαστάσεις.
- Δεύτερο επίπεδο: SAGEConv με 64 διαστάσεις.
- Τρίτο επίπεδο: SAGEConv στην τελική έξοδο.

Όπως και στο GCN, εφαρμόστηκε η ReLU μεταξύ των επιπέδων. Η εκπαίδευση ακολούθησε την ίδια διαδικασία (500 εποχές, Adam optimizer, learning rate 0.001, weight decay $5e-4$), χρησιμοποιώντας ως συνάρτηση aggregation τον μέσο όρο (mean aggregator). Τα embeddings προέκυψαν από την τελική έξοδο μετά την εκπαίδευση.

3.2.3 Node2Vec

Για τη μέθοδο Node2Vec, εφαρμόστηκαν τυχαίοι περίπατοι στον γράφο με τις εξής παραμέτρους:

- **Dimensions:** 128
- **Walk length:** 30
- **Number of walks per node:** 200
- **p=1, q=1** (παραμέτροι ισορροπημένων διερευνήσεων)

Τα embeddings εκπαιδεύτηκαν με skip-gram (window=10, min_count=1).

Τα τελικά embeddings εξήχθησαν για όλους τους κόμβους του γράφου, διατηρώντας την ίδια διάταξη με τα labels.

Συνολικά, η εξαγωγή embeddings ακολουθήθηκε για καθένα από τα δύο datasets (Cora και Citeseer), ώστε τα αποτελέσματα των μοντέλων να μπορούν να συγκριθούν στις επόμενες φάσεις (clustering και αξιολόγηση).

3.3 Εφαρμογή clustering

Αφού εξήχθησαν τα embeddings των κόμβων από τα τρία μοντέλα (GCN, GraphSAGE και Node2Vec), εφαρμόστηκαν αλγόριθμοι clustering με στόχο την ομαδοποίηση των κόμβων σε clusters, χωρίς επίβλεψη.

K-Means και Gaussian Mixture Model

Για τους αλγορίθμους K-Means και GMM, ο αριθμός των clusters (**k**) ορίστηκε ίσος με τον αριθμό των κατηγοριών (classes) που υπάρχουν στο dataset:

- Στο Cora: $k=7$
- Στο Citeseer: $k=6$

Η υλοποίηση έγινε με χρήση της βιβλιοθήκης scikit-learn, με τις υπόλοιπες παραμέτρους στις default τιμές.

DBSCAN

Για τον DBSCAN εφαρμόστηκε ειδική διαδικασία επιλογής παραμέτρων:

- Η παράμετρος min_samples ορίστηκε βάσει του εμπειρικού κανόνα $\text{min_samples} > \text{dimensions} + 1$:
 - Για embeddings διαστάσεων 128: $\text{min_samples}=129$
 - Για embeddings διαστάσεων 64: $\text{min_samples}=65$
- Η τιμή της eps προσδιορίστηκε ως εξής:
 - Υπολογίστηκαν οι αποστάσεις των σημείων από τους min_samples-1 κοντινότερους γείτονες.
 - Οι αποστάσεις ταξινομήθηκαν σε αύξουσα σειρά.
 - Σχεδιάστηκε το k-distance graph και εντοπίστηκε το σημείο καμπής (elbow point), το οποίο θεωρήθηκε κατάλληλη τιμή για την eps.

Η διαδικασία αυτή εφαρμόστηκε ξεχωριστά για κάθε σύνολο embeddings, ώστε να προσαρμόζεται στη δομή και την πυκνότητά τους.

Spectral Clustering

Για τον Spectral Clustering, ορίστηκε:

- Αριθμός clusters:
 - Cora: n_clusters=7
 - Citeseer: n_clusters=6
- affinity='nearest_neighbors' ώστε να χρησιμοποιείται πληροφορία γειτνίασης μεταξύ κόμβων.

Η υλοποίηση έγινε επίσης με χρήση της βιβλιοθήκης scikit-learn

3.4 Αξιολόγηση και εργαλεία

Για την αξιολόγηση των αποτελεσμάτων του clustering χρησιμοποιήθηκαν οι έτοιμες υλοποιήσεις των μετρικών (ARI, NMI, Silhouette Score) από τη βιβλιοθήκη **scikit-learn** για αξιοπιστία και τυποποίηση.

Επιπλέον, για την παρουσίαση των αποτελεσμάτων χρησιμοποιήθηκαν matplotlib και pandas, ώστε να δημιουργηθούν πίνακες και γραφήματα που διευκολύνουν τη σύγκριση.

Η αξιολόγηση πραγματοποιήθηκε ως εξής:

- Εκπαίδευση των μοντέλων και εξαγωγή embeddings.
- Εφαρμογή των τεσσάρων αλγορίθμων clustering (KMeans, DBSCAN, Spectral Clustering, Gaussian Mixture Model).
- Υπολογισμός ARI, NMI και Silhouette Score για κάθε συνδυασμό embeddings και clustering αλγορίθμου.
- Καταγραφή αποτελεσμάτων σε dataframes
- Οπτικοποίηση των διαχωρισμένων ομάδων με γραφήματα


Τα αποτελέσματα καταγράφηκαν και αναλύθηκαν συγκριτικά στα κεφάλαια 4 και 5

Κεφάλαιο 4 – Οπτικοποίηση και Ανάλυση Embeddings


4.1 Σκοπός και προσέγγιση

Η οπτικοποίηση των embeddings αποτελεί σημαντικό βήμα για την κατανόηση της ποιότητας των αναπαραστάσεων που παράγουν διαφορετικά μοντέλα γραφικών νευρωνικών δικτύων. Στόχος μας εδώ είναι να εξετάσουμε κατά πόσο οι κόμβοι που ανήκουν στην ίδια κατηγορία τείνουν να τοποθετούνται κοντά στο χώρο των χαρακτηριστικών και να σχηματίζουν διακριτά clusters.

Για την επίτευξη αυτού, εφαρμόσαμε τεχνικές μείωσης διαστάσεων (π.χ. t-SNE ή PCA) ώστε να περιορίσουμε τα embeddings σε δύο διαστάσεις και να μπορέσουμε να τα απεικονίσουμε σε γράφημα. Η ανάλυση πραγματοποιήθηκε ξεχωριστά για τα datasets **Cora** και **Citeseer**, και για κάθε ένα από τα τρία μοντέλα που χρησιμοποιήθηκαν: **Node2Vec**, **GCN** και **GraphSAGE**.



Σχήμα 4.1.1 Embeddings για Cora



Σχήμα 4.1.2 Embeddings για Citeseer

4.2 Embeddings για το dataset Citeseer

4.2.1 Node2Vec Embedding

Το Node2Vec δημιουργεί embeddings ακολουθώντας τυχαίους περιπάτους στον γράφο, αξιοποιώντας δηλαδή μόνο τη συνδεσιμότητα χωρίς να λαμβάνει υπόψη τα χαρακτηριστικά των

κόμβων. Στην απεικόνιση παρατηρούμε ότι οι κόμβοι κατανέμονται σε ευρύτερα νέφη σημείων χωρίς καθαρούς διαχωρισμούς, κάτι που δείχνει περιορισμένη δυνατότητα διαχωρισμού κατηγοριών.

4.2.2 GCN Embedding

Εδώ παρατηρούμε ομαδοποιήσεις, με κάποιες περιοχές να είναι πιο αραιές. Το GraphSAGE συνδυάζει πληροφορίες από τους γείτονες των κόμβων, κάτι που οδηγεί σε αρκετά καλά διαχωρισμένα clusters, αν και η διάχυση σε ορισμένες περιοχές υποδηλώνει ότι μπορεί να υπάρχουν περιπτώσεις επικάλυψης κατηγοριών.

4.2.3 GraphSAGE Embedding

Το GraphSage ενσωματώνει πληροφορία από τη δομή του γράφου και τα χαρακτηριστικά των κόμβων. Τα embeddings που προκύπτουν εμφανίζουν περισσότερο σαφή ομαδοποίηση, με τα σημεία να σχηματίζουν πιο συμπαγή clusters. Αυτό δείχνει ότι το GraphSage καταφέρνει καλύτερα να “μάθει” την υποκείμενη κατηγοριακή δομή.

4.3 Embeddings για το dataset Cora

4.3.1 Node2Vec Embedding

Στο Cora dataset, το Node2Vec παρουσιάζει ελαφρώς καλύτερη διαχωριστικότητα σε σχέση με το Citeseer, πιθανόν λόγω της διαφορετικής δομής και πυκνότητας του γράφου. Ωστόσο, εξακολουθούν να υπάρχουν αλληλοεπικαλύψεις.

4.3.2 GCN Embedding

Τα embeddings του GCN στο Cora σχηματίζουν καθαρά και συμπαγή clusters. Παρατηρείται καλύτερη διάκριση μεταξύ των κατηγοριών, γεγονός που δείχνει την αποτελεσματικότητα του GCN στη συγκεκριμένη δομή γράφου.

4.3.3 GraphSAGE Embedding

Παρόμοια εικόνα με το GCN: τα embeddings του GraphSAGE σχηματίζουν ευδιάκριτα clusters που είναι εμφανώς διαχωρίσιμα.

4.4 Συγκριτική παρατήρηση και συνολική εικόνα

Η ανάλυση των γραφημάτων οδηγεί σε ορισμένα γενικά συμπεράσματα:

- Τα **GCN** και **GraphSAGE** δημιουργούν πιο συνεκτικά και διαχωρισμένα embeddings σε σχέση με το **Node2Vec**.
- Το **Cora** εμφανίζει καλύτερη διαχωρισσιμότητα ανεξάρτητα από το μοντέλο, κάτι που σχετίζεται με τα χαρακτηριστικά και την πυκνότητα του γράφου.
- Τα embeddings του **Node2Vec**, επειδή βασίζονται αποκλειστικά σε τυχαίους περιπάτους, δεν “βλέπουν” την κατηγορία ή τα χαρακτηριστικά των κόμβων, με αποτέλεσμα να έχουν χειρότερη απόδοση στην αναπαράσταση της κατηγοριακής δομής.

Η οπτικοποίηση των embeddings δίνει μια πρώτη ποιοτική εκτίμηση για το πώς τα μοντέλα “αντιλαμβάνονται” τον γράφο, ενώ στα επόμενα κεφάλαια θα προχωρήσουμε σε ποσοτική αξιολόγηση με clustering και μετρικές.

Κεφάλαιο 5-Αποτελέσματα Clustering και Σύγκριση

5.1 Παρουσίαση αποτελεσμάτων ανά clustering μέθοδο

Σε αυτή την υποενότητα παρουσιάζουμε τα αποτελέσματα που προέκυψαν από την εφαρμογή των τεσσάρων μεθόδων clustering (KMeans, DBSCAN, Spectral Clustering και Gaussian Mixture Model) πάνω στα embeddings που παρήγαγαν τα μοντέλα GCN, GraphSAGE και Node2Vec, για τα datasets Cora και Citeseer.

Η παρουσίαση οργανώνεται ως εξής:

- **5.1.1 KMeans**
- **5.1.2 DBSCAN**
- **5.1.3 Spectral Clustering**
- **5.1.4 Gaussian Mixture Model**

Για κάθε μέθοδο clustering:


- Παρουσιάζονται τα γραφήματα που δείχνουν την κατανομή των κόμβων στα clusters (μετά από μείωση διάστασης π.χ. με t-SNE ή PCA).
- Περιγράφεται σύντομα η ποιότητα και η καθαρότητα των clusters που σχηματίστηκαν.
- Σχολιάζεται κατά πόσο η μέθοδος ανταποκρίθηκε καλά στα embeddings κάθε μοντέλου, με βάση την οπτική παρατήρηση.

Η ανάλυση συμπληρώνεται στην **ενότητα 5.2** με την παρουσίαση των πινάκων που περιλαμβάνουν τις μετρικές (**ARI, NMI, Silhouette Score κ.α.**) για ποσοτική αξιολόγηση.

5.1.1 Kmeans

Σε αυτή την ενότητα παρουσιάζονται και αναλύονται τα αποτελέσματα της εφαρμογής του αλγορίθμου KMeans πάνω στα embeddings που προήλθαν από τα τρία διαφορετικά μοντέλα (Node2Vec, GCN και GraphSAGE) για τα datasets Cora και Citeseer.

Cora



- **Node2Vec Embedding:**

Η απεικόνιση των clusters έδειξε ότι οι ομάδες είναι λιγότερο διακριτές και αρκετά διάσπαρτες. Παρατηρείται σημαντική επικάλυψη ανάμεσα σε διάφορες ομάδες, ενώ κάποιες περιοχές εμφανίζουν σχετική πυκνότητα. Αυτό υποδηλώνει ότι τα embeddings που παράγονται από το Node2Vec έχουν περιορισμένη ικανότητα να διαχωρίσουν καθαρά τις κατηγορίες κόμβων στο δίκτυο.

- **GCN Embedding:**

Τα αποτελέσματα εδώ είναι αισθητά καλύτερα. Οι ομάδες εμφανίζονται πιο καθαρά διαχωρισμένες και συνεκτικές, με έντονη διακριτότητα ανάμεσα στα clusters. Το γεγονός αυτό δείχνει ότι το GCN, αξιοποιώντας τη δομή του γράφου, καταφέρνει να παραγάγει embeddings που αντανakλούν καλύτερα την υποκείμενη δομή των δεδομένων.


- **GraphSAGE Embedding:**

Η μέθοδος αυτή εμφάνισε επίσης πολύ καλά αποτελέσματα. Οι ομάδες είναι διακριτές, με λίγη περισσότερη επικάλυψη μεταξύ ορισμένων clusters σε σχέση με το GCN, αλλά συνολικά η ποιότητα του διαχωρισμού είναι υψηλή. Αυτό αναδεικνύει τη δυνατότητα του GraphSAGE να αποτυπώνει τοπικά χαρακτηριστικά της γραφικής δομής με τρόπο που βοηθάει το clustering.

Συνολικά για το Cora:

Τα embeddings που παράγονται από τα μοντέλα GCN και GraphSAGE προσφέρουν καλύτερη βάση για τον αλγόριθμο KMeans σε σχέση με το Node2Vec, οδηγώντας σε πιο καθαρά και καλά διαχωρισμένα clusters.

Citeseer



- **Node2Vec Embedding:**

Η οπτικοποίηση έδειξε διάσπαρτες και σχετικά ασαφείς ομάδες, με αρκετή επικάλυψη και περιορισμένο διαχωρισμό μεταξύ τους. Η «θορυβώδης» κατανομή των κόμβων υποδηλώνει χαμηλότερη ποιότητα των embeddings για σκοπούς clustering.

- **GCN Embedding:**

Παρουσιάζει καλύτερη ομαδοποίηση, με σαφώς πιο διακριτές και συνεκτικές συστάδες. Τα αποτελέσματα αυτά δείχνουν ότι το GCN μπορεί να συλλάβει και να ενσωματώσει σημαντικά χαρακτηριστικά του γράφου, καθιστώντας το καταλληλότερο για clustering.

- **GraphSAGE Embedding:**

Τα αποτελέσματα είναι επίσης ιδιαίτερα καλά, με καθορισμένες ομάδες που όμως εμφανίζουν ελαφρώς περισσότερη ανομοιομορφία σε σχέση με το GCN. Η μέθοδος παραμένει αποτελεσματική και δείχνει καλή συμπεριφορά ακόμη και σε πιο δύσκολα datasets όπως το Citeseer.

Γενικά συμπεράσματα για τον KMeans:

Παρά τους περιορισμούς του, ο KMeans παραμένει μία απλή και ιδιαίτερα γρήγορη μέθοδος clustering, που προσφέρει ευκολία στην εφαρμογή και ευκρινή αποτελέσματα όταν τα δεδομένα έχουν σχετικά κανονική δομή.

Στην περίπτωση μας, φάνηκε ότι αξιοποιώντας καλύτερα embeddings (όπως αυτά από τα GCN και GraphSAGE), ο KMeans καταφέρνει να δημιουργήσει καθαρά και συνεκτικά clusters, αποδεικνύοντας την αξία του ως αφετηρία για την ανάλυση δομημένων δεδομένων.

Ειδικά σε μεγάλα datasets όπως το Cora και το Citeseer, ο KMeans παραμένει αξιόπιστος και υπολογιστικά αποδοτικός, προσφέροντας γρήγορη πρώτη εκτίμηση της ποιότητας των embeddings.

5.1.2 DBSCAN



Και στο Citeseer και στο Cora, παρατηρείται παρόμοια συμπεριφορά στον DBSCAN, ανεξάρτητα από το ποιο embedding χρησιμοποιείται:

- **Node2Vec:** Δημιουργεί κυρίως ένα μεγάλο cluster και αρκετά σημεία μένουν ως outliers. Αν και υπάρχουν τοπικές περιοχές πυκνότητας, ο DBSCAN δεν καταφέρνει να τις ανιχνεύσει σωστά.
- **GCN & GraphSAGE:** Σχηματίζεται ένας μεγάλος μονολιθικός σχηματισμός με λίγους outliers. Το GCN δίνει πιο συνεκτικά embeddings, αλλά χωρίς διακριτές τοπικές πυκνότητες, ενώ και με το GraphSAGE ο DBSCAN δυσκολεύεται να εντοπίσει καθαρά clusters.


Συμπερασματικά, ο DBSCAN εμφανίζει περιορισμένη αποτελεσματικότητα λόγω:

- ευαισθησίας σε παραμέτρους (eps , $min_samples$),
- δυσκολίας σε δεδομένα υψηλής διάστασης,
- και ανομοιομόρφων κατανομών που προκύπτουν από embeddings.

Τα αποτελέσματα δείχνουν πως οι δυσκολίες σχετίζονται κυρίως με τον ίδιο τον αλγόριθμο και όχι τόσο με την ποιότητα των embeddings.

5.1.3 Spectral

Citeseer



- **Node2Vec Embedding:**

Η πλειοψηφία των σημείων εντάσσεται σε μία μεγάλη συστάδα, με μόνο λίγες μικρές και διάσπαρτες ομάδες. Η κατανομή μοιάζει επίπεδη και ομοιογενής, χωρίς έντονη διαφοροποίηση. Αυτό δείχνει ότι το Spectral Clustering δεν καταφέρνει να εκμεταλλευτεί επαρκώς τη δομή των Node2Vec embeddings, πιθανώς επειδή αυτά τα embeddings δεν αποτυπώνουν σε βάθος τη γραφική πληροφορία που απαιτεί ο αλγόριθμος.


- **GCN Embedding:**

Ο διαχωρισμός σε ομάδες είναι καθαρός και εμφανής, με καλά ορισμένες συστάδες που συμφωνούν με την κατανομή των δεδομένων. Η ποιότητα του διαχωρισμού δείχνει ότι τα GCN embeddings συνεργάζονται αποτελεσματικά με τον Spectral Clustering, αξιοποιώντας τη δομή του γράφου και οδηγώντας σε ουσιαστική ομαδοποίηση.

- **GraphSAGE Embedding:**

Παρατηρούνται επίσης καλά διαχωρισμένες και συμπαγείς συστάδες, αν και σε κάποια σημεία υπάρχει ελαφρύ overlapping ή «θόρυβος». Γενικά όμως, το αποτέλεσμα δείχνει καλή αξιοποίηση των τοπικών γειτονιών και της γραφικής πληροφορίας, με ποικιλία και γεωμετρική συνοχή στις ομάδες.

Cora



- **Node2Vec Embedding:**

Οι περισσότερες τελείες έχουν ίδιο χρώμα, δείχνοντας ότι το Spectral Clustering «κατέρρευσε» σε μία κυρίαρχη κατηγορία. Μόνο λίγες μικρές ομάδες εμφανίζονται στην άκρη του χώρου. Αυτό φανερώνει ότι τα Node2Vec embeddings δεν είναι επαρκώς διαχωρίσιμα ώστε να δώσουν νόημα στον Spectral Clustering.

- **GCN Embedding:**

Ο Spectral Clustering καταφέρνει να διαχωρίσει καθαρά 3–4 ομάδες, με καλά ορισμένους πυρήνες και μικρή επικάλυψη. Αυτό αποδεικνύει τη δύναμη των GCN embeddings να δημιουργούν δομές που ευνοούν τον διαχωρισμό βάσει φασματικών ιδιοτήτων.

- **GraphSAGE Embedding:**


Παρουσιάζει επίσης καλή ομαδοποίηση, παρόμοια με το GCN, με ελαφρώς περισσότερη ανάμειξη σε κάποια σημεία. Ωστόσο, οι ομάδες είναι γεωμετρικά συνεκτικές και σαφώς διαχωρισμένες, υποδεικνύοντας ότι τα GraphSAGE embeddings ταιριάζουν καλά σε μεθόδους όπως το Spectral Clustering.

Γενικό Συμπέρασμα:

Το Spectral Clustering αξιοποιεί καλύτερα embeddings που ενσωματώνουν ρητά τη δομή του γράφου, όπως τα GCN και GraphSAGE, προσφέροντας καθαρούς και οπτικά πειστικούς διαχωρισμούς. Στα Node2Vec embeddings, που στηρίζονται περισσότερο σε random walks, το αποτέλεσμα είναι σαφώς πιο αδύναμο.

5.1.4 GMM

Cora




- **Node2Vec Embedding:**

- Καλή ομαδοποίηση, με ξεκάθαρες «μπάλες» από κόμβους.
- Ορισμένα clusters φαίνονται ιδιαίτερα συμπαγή (π.χ. στο αριστερό τμήμα).

- Αρκετά καλή επιλογή για γενική αποτύπωση της δομής.
- **GCN Embedding:**
 - Σαφώς διαχωρισμένες ομάδες.
 - Πιο «μαζεμένες» και φυσικές κατανομές.
 - Η χρήση χαρακτηριστικών κόμβων και γραφικής δομής ενισχύει την ικανότητα διαχωρισμού.
- **GraphSAGE Embedding:**
 - Παρόμοια εικόνα με το GCN.
 - Λίγο πιο διάσπαρτα clusters, που δείχνουν τοπικές διαφοροποιήσεις.
 - Αποτυπώνει λεπτομέρειες μεταξύ γειτονικών κόμβων.

Citeseer



- **Node2Vec Embedding:**
 - Οι ομάδες είναι πιο ανακατεμένες, με αρκετή επικάλυψη.
 - Διακρίνονται στρογγυλές περιοχές πυκνότητας κοντά στο κέντρο.
 - Συνολικά πιο «θορυβώδης» κατανομή.
- **GCN Embedding:**
 - Καλύτερη ομαδοποίηση από το Node2Vec.
 - Ξεκάθαρα clusters, αν και με ορισμένες περιοχές επικάλυψης.
 - Όχι τόσο καλά διαχωρισμένα όσο στο Cora.
- **GraphSAGE Embedding:**
 - Πιο καθαρές και απομονωμένες ομάδες.
 - Γεωμετρικά συνεκτικά clusters.
 - Δείχνει πολύ καλή απόδοση στο συγκεκριμένο dataset.

5.2 Παρουσίαση πινάκων με τις μετρικές

Η ανάλυση των αποτελεσμάτων clustering που εφαρμόστηκαν στα embeddings των datasets Cora και Citeseer ανέδειξε ορισμένα σημαντικά συμπεράσματα για την καταλληλότητα των διαφορετικών μεθόδων και τύπων embeddings.

Πίνακας: Αποτελέσματα στο Cora

Clustering Method	Embedding	Silhouette	ARI	NMI
kmeans	Node2Vec	0.08	0.36	0.43
kmeans	GCN	0.40	0.59	0.60
kmeans	GraphSAGE	0.42	0.60	0.60
DBSCAN	Node2Vec	0.20	-0.01	0.01
DBSCAN	GCN	0.58	0.00	0.00
DBSCAN	GraphSAGE	-0.15	0.01	0.02
Spectral	Node2Vec	0.06	0.00	0.13
Spectral	GCN	0.40	0.63	0.64
Spectral	GraphSAGE	0.41	0.63	0.63
GMM	Node2Vec	0.08	0.36	0.43
GMM	GCN	0.32	0.50	0.57
GMM	GraphSAGE	0.38	0.57	0.60

Πίνακας: Αποτελέσματα στο Citeseer

Clustering Method	Embedding	Silhouette	ARI	NMI
kmeans	Node2Vec	0.05	0.16	0.21
kmeans	GCN	0.33	0.38	0.37
kmeans	GraphSAGE	0.23	0.30	0.35
DBSCAN	Node2Vec	-0.18	0.01	0.06
DBSCAN	GCN	0.17	0.00	0.00
DBSCAN	GraphSAGE	0.10	0.00	0.01
Spectral	Node2Vec	0.02	0.12	0.16
Spectral	GCN	0.32	0.39	0.38
Spectral	GraphSAGE	0.25	0.18	0.36

Στο Cora, παρατηρούμε γενικά υψηλότερες μετρικές, ιδίως όταν χρησιμοποιούνται embeddings από GCN και GraphSAGE, γεγονός που δείχνει καλύτερη ποιότητα διαχωρισμού.

- **KMeans Clustering**

- Τα embeddings GCN και GraphSAGE πετυχαίνουν παρόμοιες και καλές τιμές: Silhouette $\sim 0.40\text{--}0.42$ και ARI/NMI $\sim 0.59\text{--}0.60$.
- Το Node2Vec εμφανίζει χαμηλή απόδοση (Silhouette 0.08, ARI 0.36, NMI 0.43), αποδεικνύοντας ότι τα δομικά embeddings οδηγούν σε καλύτερη ομαδοποίηση.
- **Spectral Clustering**
 - Πολύ καλή απόδοση στα GCN και GraphSAGE embeddings (Silhouette $\sim 0.40\text{--}0.41$, ARI/NMI $\sim 0.63\text{--}0.64$).
 - Στο Node2Vec οι τιμές παραμένουν χαμηλές, δείχνοντας αδυναμία διαχωρισμού.
- **GMM Clustering**
 - Στα GCN και GraphSAGE δίνει μέτρια προς καλές επιδόσεις (Silhouette $\sim 0.32\text{--}0.38$, ARI/NMI $\sim 0.50\text{--}0.60$).
 - Στο Node2Vec οι μετρικές παραμένουν χαμηλές.
- **DBSCAN**
 - Πολύ αστάθμητα αποτελέσματα: σε κάποιες περιπτώσεις (GCN) εμφανίζεται υψηλό Silhouette (0.58) αλλά μηδενικό ARI/NMI, ενώ σε άλλες περιπτώσεις οι μετρικές είναι χαμηλές ή αρνητικές.
 - Η μέθοδος αυτή δεν αποδίδει καλά λόγω ανομοιομορφίας στην πυκνότητα των embeddings.

Στο Citeseer οι επιδόσεις είναι χαμηλότερες, κάτι που δείχνει ότι το clustering είναι πιο δύσκολο.

- **KMeans Clustering**
 - Το GCN παρουσιάζει τις καλύτερες τιμές (Silhouette 0.33, ARI 0.38, NMI 0.37).
 - Ακολουθεί το GraphSAGE με μέτρια αποτελέσματα, ενώ το Node2Vec αποτυγχάνει να διαχωρίσει ικανοποιητικά τα δεδομένα (Silhouette 0.05, ARI 0.16, NMI 0.21).
- **Spectral Clustering**
 - Πολύ καλή απόδοση στο GCN (Silhouette 0.32, ARI 0.39, NMI 0.38).
 - Στο GraphSAGE οι τιμές είναι μέτριες (Silhouette 0.25, ARI 0.18, NMI 0.36).
 - Στο Node2Vec παραμένουν πολύ χαμηλές.
- **DBSCAN**
 - Αποδίδει εξαιρετικά χαμηλά ή και αρνητικά αποτελέσματα σε όλα τα embeddings, με σχεδόν μηδενικό ARI/NMI.

Συνολικά, στο Citeseer είναι φανερό ότι ο διαχωρισμός είναι πιο δύσκολος και μόνο embeddings όπως του GCN καταφέρνουν ικανοποιητικό clustering, ενώ το Cora εμφανίζει καθαρότερα clusters με embeddings που αξιοποιούν τη γραφική πληροφορία, και οι καλύτερες μέθοδοι clustering είναι το kMeans και το Spectral.

5.3 Συγκριτική ανάλυση μεταξύ μοντέλων (GCN vs GraphSAGE vs Node2Vec)

Η συγκριτική ανάλυση των τριών μοντέλων δείχνει ξεκάθαρα ότι οι μέθοδοι βασισμένες σε **γραφονευρωνικά δίκτυα (GCN και GraphSAGE)** προσφέρουν ποιοτικότερα embeddings για σκοπούς clustering, σε σύγκριση με την προσέγγιση **Node2Vec**.

- Το **GCN** εμφάνισε σταθερά καλύτερη διαχωριστικότητα, δημιουργώντας πιο συμπαγείς και σαφώς ορισμένες ομάδες, ιδίως όταν συνδυάστηκε με Spectral Clustering ή KMeans.
- Το **GraphSAGE** παρουσίασε παρόμοια ισχυρή απόδοση, με ελαφρώς πιο διάσπαρτα clusters, αλλά και μεγαλύτερη λεπτομέρεια, ειδικά σε τοπικές δομές.
- Αντίθετα, το **Node2Vec** είχε την τάση να παράγει πιο θορυβώδη embeddings, με σημαντική επικάλυψη μεταξύ των ομάδων, κάτι που δυσκόλεψε τις μεθόδους clustering να εντοπίσουν καθαρούς διαχωρισμούς.

Οι μετρικές αξιολόγησης (όπως ARI, NMI και Silhouette) επιβεβαιώνουν τα παραπάνω ευρήματα, αναδεικνύοντας τη σαφή υπεροχή των GNN-based μεθόδων.

5.4 Συζήτηση για τα datasets (Cora vs Citeseer)

Η ανάλυση των αποτελεσμάτων έδειξε επίσης διαφορές στην ποιότητα του clustering ανάλογα με το dataset:

- Στο **Cora**, οι μέθοδοι clustering πέτυχαν καλύτερα αποτελέσματα συνολικά. Τα embeddings είχαν πιο συμπαγείς και ξεκάθαρα διαχωρισμένες ομάδες, γεγονός που υποδηλώνει ότι η εσωτερική δομή του γράφου (π.χ. κοινότητες και θεματικές ενότητες) διευκολύνει την ομαδοποίηση.
- Στο **Citeseer**, παρατηρήθηκε περισσότερη επικάλυψη μεταξύ των ομάδων και λιγότερο σαφής διαχωρισμός. Αυτό ενδέχεται να οφείλεται στη φύση του γράφου, που παρουσιάζει χαμηλότερη συνδεσιμότητα ή μεγαλύτερη ετερογένεια στους κόμβους.

Γενικά, και στα δύο datasets τα GNN embeddings αποδίδουν καλύτερα από το Node2Vec, αλλά τα χαρακτηριστικά του ίδιου του γράφου επηρεάζουν την τελική ποιότητα των clusters.

Κεφάλαιο 6-Συμπεράσματα και Μελλοντικές Κατευθύνσεις

6.1 Ανακεφαλαίωση

Η εργασία ανέλυσε την ποιότητα και τη χρησιμότητα διαφορετικών embeddings γράφου για το clustering, μέσα από την εφαρμογή και σύγκριση τεσσάρων μεθόδων clustering (KMeans, DBSCAN, Spectral Clustering, GMM) σε δύο γνωστά datasets (Cora και Citeseer). Από τη συνολική μελέτη προκύπτουν τα εξής βασικά συμπεράσματα:

Υπεροχή GNN-based μεθόδων (GCN & GraphSAGE):

- Τα embeddings που προκύπτουν από γραφο-νευρωνικά δίκτυα είναι πιο ποιοτικά και οδηγούν σε σαφέστερα και συμπαγέστερα clusters.
- Ειδικά το GCN είχε πολύ καλή διαχωριστικότητα, ενώ το GraphSAGE αποτύπωσε και λεπτές τοπικές διαφοροποιήσεις.

Περιορισμοί Node2Vec:

- Παρά το ότι είναι μια κλασική και γενική προσέγγιση, το Node2Vec απέδωσε χαμηλότερης ποιότητας embeddings για clustering, με συχνή επικάλυψη ομάδων και «θορυβώδη» κατανομή κόμβων.

Συμπεριφορά των μεθόδων clustering:

- Το **KMeans** και το **Spectral Clustering** αποδείχθηκαν πιο σταθερά και αποτελεσματικά για τα δεδομένα που προέκυψαν από GNN embeddings.
- Αντίθετα, το **DBSCAN** επηρεάστηκε έντονα από τις παραμέτρους και δεν κατάφερε να εντοπίσει σωστά τα clusters στις περισσότερες περιπτώσεις.
- Το **GMM** ήταν καλύτερο από τον DBSCAN, αλλά και πάλι ευαίσθητο σε επικαλύψεις και μη κανονικές κατανομές.

Επίδραση της δομής των datasets:

- Το dataset **Cora** είχε γενικά πιο καθαρές, ομοιογενείς ομάδες, με λιγότερη επικάλυψη, κάτι που διευκόλυνε το clustering.
- Το **Citeseer** εμφάνισε περισσότερη ετερογένεια και δυσκολία στο διαχωρισμό, ανεξαρτήτως embedding.

6.2 Μελλοντική επέκταση και βελτίωση

Η παρούσα εργασία ανέδειξε ενδιαφέροντα συμπεράσματα σχετικά με τον ρόλο των embeddings και της δομής των γράφων στην ποιότητα του clustering. Ωστόσο, υπάρχουν αρκετές κατευθύνσεις για περαιτέρω μελέτη και βελτίωση:

Προχωρημένα embeddings:

- Μπορούν να δοκιμαστούν πιο πρόσφατα μοντέλα γραφικών νευρωνικών δικτύων, όπως **Graph Attention Networks (GAT)** ή **Graph Isomorphism Networks (GIN)**, που ενσωματώνουν δυναμικά βάρη στις ακμές ή πιο εκφραστικές αναπαραστάσεις.
- Παράλληλα, οι τεχνικές *contrastive learning* και *self-supervised learning* μπορούν να ενισχύσουν την ποιότητα των embeddings χωρίς επιπλέον εποπτεία.

Μελέτη σε πιο σύνθετους γράφους:

- Τα πειράματα περιορίστηκαν σε σχετικά «καθαρά» citation networks (Cora, Citeseer). Η εφαρμογή σε πιο ετερογενείς ή δυναμικούς γράφους (π.χ. κοινωνικά δίκτυα ή transaction networks) θα μπορούσε να αποκαλύψει περισσότερα για την ανθεκτικότητα και γενίκευση των μοντέλων.

Συνδυασμός εποπτευόμενων και μη εποπτευόμενων μεθόδων:

- Μια μελλοντική επέκταση θα ήταν να συνδυαστούν τα unsupervised embeddings με λίγη εποπτευόμενη πληροφορία (semi-supervised learning) ώστε να βελτιωθεί περαιτέρω η ποιότητα των clusters.

⇒ Τελική σκέψη:

Η συνεχιζόμενη ανάπτυξη των γραφικών νευρωνικών δικτύων και η καλύτερη κατανόηση της δομής των γράφων μπορούν να βελτιώσουν σημαντικά το clustering και να προσφέρουν χρήσιμες εφαρμογές σε ποικίλα πεδία — από την ανάλυση κοινωνικών δικτύων έως τη βιοπληροφορική και την ανίχνευση ανωμαλιών.

Παράρτημα

Παράρτημα Α – Κώδικας

A.1 Φόρτωση βιβλιοθηκών και δεδομένων

```
from torch_geometric.datasets import Planetoid
import torch
from torch.nn import Dropout, BatchNorm1d
import torch.nn.functional as F
from torch_geometric.nn import GCNConv, SAGEConv
import torch_geometric.transforms as T
import networkx as nx
from node2vec import Node2Vec
from torch_geometric.utils import to_networkx
import matplotlib.pyplot as plt
import numpy as np
from sklearn.cluster import KMeans, DBSCAN
from sklearn.metrics import adjusted_rand_score, normalized_mutual_info_score,
silhouette_score
from sklearn.manifold import TSNE
import pandas as pd
from sklearn.neighbors import NearestNeighbors
from sklearn.decomposition import PCA

# Φόρτωση Cora και Citeseer
data_cora = Planetoid(root='data/Planetoid', name='Cora')[0]
data_citeseer = Planetoid(root='data/Planetoid', name='Citeseer')[0]

# Μετατροπή σε NetworkX graphs
G_cora = to_networkx(data_cora, to_undirected=True)
G_citeseer = to_networkx(data_citeseer, to_undirected=True)
```

A.2 Βασικές πληροφορίες και οπτικοποιήσεις

```
def print_graph_info(data, name):
    print(f"\nDataset: {name}")
    print(f"Nodes: {data.num_nodes}")
    print(f"Edges: {data.num_edges}")
    print(f"Features per node: {data.num_node_features}")
    print(f"Number of classes: {data.y.max().item() + 1}")

print_graph_info(data_cora, "Cora")
print_graph_info(data_citeseer, "Citeseer")

def draw_full_graph(G, title):
    plt.figure(figsize=(10, 10))
    nx.draw(G, node_size=30, with_labels=False, edge_color="gray", alpha=0.7)
    plt.title(title)
    plt.axis('off')
    plt.show()

draw_full_graph(G_cora, "Cora Graph")
draw_full_graph(G_citeseer, "Citeseer Graph")
```

```

def plotResults(name, methods, embeddings_list, predictions_list):

    fig, axes = plt.subplots(1, 3, figsize=(24, 6))

    fig.suptitle(name, fontsize=16)

    for i in range(3):

        tsne = TSNE(n_components=2, random_state=42, perplexity=30)

        reduced = tsne.fit_transform(embeddings_list[i])

        axes[i].scatter(reduced[:, 0], reduced[:, 1], c=predictions_list[i],
cmap='viridis', s=30)

        axes[i].set_title(f'{methods[i]} Embedding')

    plt.tight_layout(rect=[0, 0.03, 1, 0.95])

    plt.show()

```

A.3 Ορισμός μοντέλων GCN και GraphSAGE

```

class GCN(torch.nn.Module):
    def __init__(self, in_channels, hidden_channels, out_channels):
        super(GCN, self).__init__()
        self.conv1 = GCNConv(in_channels, hidden_channels)
        self.bn1 = BatchNorm1d(hidden_channels)
        self.dropout = Dropout(0.5)
        self.conv2 = GCNConv(hidden_channels, out_channels)

    def forward(self, x, edge_index):
        x = self.conv1(x, edge_index)
        x = self.bn1(x)
        x = F.relu(x)
        x = self.dropout(x)
        x = self.conv2(x, edge_index)
        return x

class GraphSAGE(torch.nn.Module):
    def __init__(self, in_channels, hidden_channels, out_channels):
        super(GraphSAGE, self).__init__()
        self.conv1 = SAGEConv(in_channels, hidden_channels)
        self.bn1 = BatchNorm1d(hidden_channels)
        self.dropout = Dropout(0.5)
        self.conv2 = SAGEConv(hidden_channels, out_channels)

    def forward(self, x, edge_index):
        x = self.conv1(x, edge_index)
        x = self.bn1(x)
        x = F.relu(x)
        x = self.dropout(x)
        x = self.conv2(x, edge_index)
        return x

```

A.4 Εκπαίδευση και εξαγωγή embeddings

```
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
model = GCN(data_cora.num_node_features, 128, 64).to(device)
data = data_cora.to(device)

optimizer = torch.optim.Adam(model.parameters(), lr=0.01, weight_decay=5e-4)

model.train()
for epoch in range(200):
    optimizer.zero_grad()
    out = model(data.x, data.edge_index)
    loss = F.cross_entropy(out[data.train_mask], data.y[data.train_mask])
    loss.backward()
    optimizer.step()
```

A.5 Clustering και μετρικές

```
embeddings = out.detach().cpu().numpy()
kmeans = KMeans(n_clusters=7, random_state=42).fit(embeddings)
labels = kmeans.labels_

ari = adjusted_rand_score(data.y.cpu(), labels)
nmi = normalized_mutual_info_score(data.y.cpu(), labels)
silhouette = silhouette_score(embeddings, labels)

print(f"ARI: {ari:.4f}, NMI: {nmi:.4f}, Silhouette: {silhouette:.4f}")
```

A.6 Οπτικοποίηση embeddings με t-SNE

```
tsne = TSNE(n_components=2, random_state=42)
embeddings_2d = tsne.fit_transform(embeddings)

plt.figure(figsize=(8, 8))
plt.scatter(embeddings_2d[:, 0], embeddings_2d[:, 1], c=labels, cmap='tab10',
            s=10)
plt.title('t-SNE visualization of embeddings')
plt.axis('off')
plt.show()
```
